

공유오피스 무료체험 고객의 결제 전환 예측과 서비스 개선 방향

코드잇 스프린트
데이터 분석가 16기

파트 3 중간 프로젝트
강사 김민지
코치 강지은
멘토 오세규

2팀 안2잘부
팀장 홍석훈
팀원 권예선
박다물
원예은
이지훈
조진항

2026.09.29

목 차

종합 요약.....	4
1. 배경 및 문제 정의.....	5
1.1 프로젝트 배경.....	5
1.2 비즈니스 질문.....	5
1.3 목표와 지표.....	5
2. 데이터 구성과 분석 범위.....	5
2.1 원본 데이터.....	5
2.2 테이블 관계와 분석 단위.....	6
2.3 분석 대상.....	7
2.4 관찰 기간 정의.....	7
3. 데이터 품질 검증 및 전처리.....	7
3.1 타입 변환과 타임존 보정.....	7
3.2 중복 처리.....	8
3.3 시각 결측 복원.....	9
3.4 테이블 정합성 확인 및 제외 기준.....	10
3.5 자정 이어짐 병합.....	11
3.6 체험 기간 적용.....	12
3.7 체류시간 이상치 확인.....	12
3.8 사용자 피처 생성.....	12
4. 탐색적 데이터 분석.....	13
4.1 무료체험 퍼널.....	13
4.2 재방문과 결제.....	14
4.3 체류시간과 결제.....	14
4.4 첫 입실 시각 및 시간당 방문 세션 수와 결제.....	15
4.5 EDA 종합.....	15
5. 결제 전환 예측 모델링.....	16
5.1 문제 정의.....	16
5.2 모델링 파이프라인.....	16
5.3 파생변수.....	17
5.4 변수 선택.....	18
5.5 임계값.....	19
5.6 최종 모델 성능.....	20
6. 모델 해석.....	21
7. 비즈니스 활용 및 서비스 개선 제안.....	22
7.1 활용 원칙.....	22
7.2 액션 제안.....	22
7.3 검증 방법.....	23
8. 한계와 추가 필요 데이터.....	24
8.1 분석 한계.....	24
8.2 추가 수집 데이터 제안.....	24
9. 결론.....	25
부록 A. 보고서용 핵심 수치.....	26
부록 B. 모델 비교 및 개선.....	27

표 목차

표 1. 원본 데이터 구성.....	6
표 2. 분석 대상별 고객 수와 결제율.....	7
표 3. 타임존 보정 전후 입실 피크 시각.....	8
표 4. 중복 유형별 처리 기준.....	8
표 5. 테이블별 완전 중복 제거 결과.....	9
표 6. 출입 로그 기반 시각 복원 검증 결과.....	9
표 7. 입·퇴실 시각 결측 복원 결과.....	10
표 8. 테이블 간 사용자 정합성 검증 결과.....	11
표 9. 자정 연속 이용 병합 예시.....	11
표 10. 체험 기간 적용 전후 기록 수.....	12
표 11. 체류시간 이상치 검토 결과.....	12
표 12. 결제 전환 예측 모델 구성.....	16
표 13. 파생변수 정의.....	18
표 14. 변수 선택 단계별 변수 수.....	18
표 15. 분석 임계값 적용 결과 혼동행렬.....	19
표 16. 최종 CatBoost 모델 성능.....	20
표 17. 주요 변수의 예측 기여도와 방향.....	21
표 18. 첫 방문 후 재방문 안내 A/B 테스트 설계.....	24
표 19. 분석 핵심 수치.....	26
표 20. 모델 비교 및 개선 결과.....	27

그림 목차

그림 1. 데이터 테이블 관계도.....	6
그림 2. 무료체험 신청·방문·재방문 퍼널.....	14
그림 3. 방문 단계별 고객 수와 결제율.....	14
그림 4. 체류시간 지표별 구간 결제율.....	15
그림 5. 첫 입실 시각 및 시간당 방문 세션 수별 결제율.....	15
그림 6. 모델 학습 및 검증 파이프라인.....	17
그림 7. 변수 선택·튜닝 및 최종 평가 절차.....	17
그림 8. 분석 임계값 적용 결과 혼동행렬.....	19
그림 9. 주요 변수의 SHAP 중요도와 방향.....	22
그림 10. 모델 개선 단계별 교차검증 ROC-AUC 변화.....	28

종합 요약

본 프로젝트는 공유오피스 3일 무료체험 신청·방문·출입·결제 데이터를 이용해 고객 행동과 결제 전환의 관계를 분석하고, 결제 가능성을 예측하여 서비스 개선 방향을 제안하는 것을 목적으로 한다.

원본 5개 테이블의 중복, 시각 결측, 타임존 차이, 자정 연속 이용, 복수 신청 및 데이터 끝 절단 문제를 검증했다. 특히 입·퇴실 시각 결측 555행은 임의로 삭제하지 않고 동일 사용자·날짜·지점의 출입 로그로 복원했다. 정상 행에서 복원 방식을 검증한 결과 1분 이내 일치율은 입실 93.9%, 퇴실 92.1%였으며, 정합성 검사를 통과한 395행을 복원했다. 최종 분석 대상은 9,458명이다.

EDA 결과, 신청자 9,458명 중 6,377명(67%)이 방문했고 2,955명(31%)이 재방문했다. 방문자의 54%는 하루만 이용하고 종료했다. 재방문 고객의 결제율은 45.2%로 비재방문 고객의 34.4%보다 10.8%p 높았다. 반면 하루 평균 체류시간이 0~4시간인 고객의 결제율은 약 44%, 8시간 이상인 고객은 약 30%로, 오래 머무는 행동이 높은 결제로 곧바로 이어지지 않는 않았다. 첫 입실이 18시 이후인 고객은 약 50%의 결제율을 보여 주간 이용 고객의 34~39%보다 높았다.

결제 예측은 행동 정보가 존재하는 방문 고객을 대상으로 수행했다. 단순 방문일수 모델의 테스트 ROC-AUC는 0.591이었고, 여러 행동 변수를 반영한 최종 CatBoost 모델은 0.648을 기록했다. 운영 임계값 0.366에서 Precision 0.501, Recall 0.665, F1 0.571이었다. 모델은 개별 고객의 결제를 확정적으로 판단할 수준은 아니지만, 단일 방문일수보다 다양한 행동을 함께 사용하는 것이 고객의 상대적 전환 가능성을 구분하는 데 도움이 됨을 확인했다.

모델 해석에서는 마지막 방문일, 방문 기간, 평균 입실 시각이 주요 신호로 나타났다. 이 결과는 인과관계가 아니라 결제여부와 관련성으로 해석한다. 실제 개선 효과를 확인하기 위한 후속 실험을 제안한다.

1. 배경 및 문제 정의

1.1 프로젝트 배경

공유오피스의 무료체험은 잠재 고객이 실제 공간과 서비스를 경험한 뒤 유료 이용을 결정하게 하는 전환 단계다. 무료체험 신청자 수만 늘리는 것보다 신청자가 실제로 방문하고, 서비스를 이용하며, 최종 결제로 이어지는 과정을 이해하는 것이 중요하다.

기업은 전체 체험 고객을 대상으로 동일한 수준의 서비스 경험을 제공하기 어렵다. 따라서 고객의 행동 기록으로 결제전환 가능성을 예측할 수 있다면 상담, 재방문 안내, 상품 추천 등 한정된 운영 자원을 더 효율적으로 배분할 수 있다.

1.2 비즈니스 질문

본 프로젝트는 다음 질문에 답하고자 한다.

1. 무료체험 신청자는 방문·재방문·결제로 어떻게 이동하는가?
2. 방문일수, 체류시간, 출입 횟수, 이용 시간대 및 지점 특성은 결제 여부와 어떤 관련이 있는가?
3. 무료체험 중 관찰된 이용행동으로 방문 고객의 결제 가능성을 어느 정도 예측할 수 있는가?
4. 모델과 EDA가 공통적으로 제시하는 주요 변수 중 직접적으로 개선할 수 있는 요인은 무엇인가?
5. 현재 데이터로 설명하지 못하는 결제 결정 요인은 무엇이며, 어떤 데이터를 추가로 수집해야 하는가?

1.3 목표와 지표

- 핵심 KPI: 결제 전환율
- 퍼널 지표: 방문율, 재방문율
- 행동지표: 방문일수, 체류시간, 출입 횟수, 이용 시간대, 지점 수
- 모델 평가지표: ROC-AUC, Precision, Recall, F1, Accuracy

재방문율은 최종 성과가 아니라 결제로 이어지는 과정을 진단하는 중간지표로 사용한다.

2. 데이터 구성과 분석 범위

2.1 원본 데이터

분석에서는 무료체험 신청·결제·방문·출입·지점 정보를 담은 5개 테이블을 사용했다. 관측 기간은 2021년 5월부터 2023년 12월 31일까지다.

테이블	원본 행 수	고유 사용자	의미	주요 컬럼
trial_register	9,659	9,624	사용자 1명의 신청	user_uuid, trial_date
trial_payment	9,659	9,624	사용자 1명의 결제 결과	user_uuid, is_payment
trial_visit_info	11,477	6,534	사용자-지점-날짜 방문	site_id, date, first_enter_time, last_leave_time, stay_time_second
trial_access_log	63,708	6,026	출입 이벤트 1건	id, checkin(1=입실, 2=퇴실), cdate, site_id
site_area	9	-	지점 1개	site_id, area_pyeong

표 1. 원본 데이터 구성

신청 테이블은 원본 9,659행이지만 고유 사용자는 9,624명으로, 행과 사용자 수의 차이는 중복 기록과 복수 신청에서 발생했다.

2.2 테이블 관계와 분석 단위

테이블마다 한 행이 의미하는 단위가 달라, 결합 전에 분석 단위를 먼저 확인했다.




그림 1. 데이터 테이블 관계도

최종 분석 단위는 사용자 1명 = 1행이다. 방문·출입 기록은 1:N 관계이므로, 결합 전에 사용자 단위로 집계해 행이 중복으로 늘어나지 않도록 했다. 신청·결제 테이블을 결합의 기준으로 두고, 방문·출입 집계 결과를 left join해 미방문 고객도 행을 유지했다.

2.3 분석 대상

구분	인원	결제율
원본 신청 사용자	9,624명	-
품질 검증 및 제외 기준 적용 후 최종 사용자	9,458명	37.8%
↳ 방문 고객 (D0~D3 방문 기록 있음)	6,377명	39.0%
↳ 미방문 고객	3,081명	35.2%

표 2. 분석 대상별 고객 수와 결제율

- EDA 대상: 최종 사용자 9,458명 전체
- 결제 예측 대상: 방문 고객 6,377명 (학습 5,120명 / 테스트 1,257명)

미방문 고객은 전체 퍼널과 방문 유도 전략 분석에는 포함했다. 다만 체류시간·입실 시각 같은 행동 변수가 없으므로, 행동 기반 결제 예측은 방문 고객을 대상으로 했다.

2.4 관찰 기간 정의

신청일을 D0으로 두고, 각 방문의 체험 일차를 방문 시작일 - 신청일로 계산했다. 방문 기록에서 D3까지 방문이 확인되며, D3 방문 고객 1,999명 중 1,001명이 미결제 고객이었다. 이에 D3 이용을 체험 기간 내 행동으로 보고 EDA와 결제 예측 모두 D0~D3의 이용 기록을 사용했다. 단, 출입 로그는 원본 데이터에 D0~D2 기록만 존재하므로 D3는 방문·체류 정보만 반영한다.

결제 시각이 제공되지 않아 행동과 결제의 정확한 선후관계는 확인할 수 없다. 따라서 본 모델은 체험 도중의 실시간 조기에측 모델이 아니라, 무료체험 전체 행동으로 최종 결제 고객을 구분하는 사후 분류 모델로 정의한다. 특히 D3 행동에는 결제 이후 이용이 포함됐을 가능성이 있으므로 변수 중요도는 결제 원인이 아니라 결제 고객에게 함께 나타난 행동 특성으로 해석한다. 체험 종료 전 개입이 목적이라면 향후 D0~D2만 사용한 별도 조기에측 모델이 필요하다.

3. 데이터 품질 검증 및 전처리

3.1 타임 변환과 타임존 보정

타임 변환: 날짜·시각 컬럼을 **datetime** 형식으로 변환했다. 시각 문자열에 소수점 이하 초가 포함된 값과 포함되지 않은 값이 혼재되어, 소수점 이하 초를 포함하지 않은 초 단위로 통일했다. 이는 테이블 간 시각 정밀도 차이로 인해 데이터 결합 및 시간 비교 과정에서 발생할 수 있는 오류를 방지하기 위한 처리다. 체류시간은 문자열 형식의 **stay_time** 대신 정수형 초 단위 컬럼인 **stay_time_second**를 사용했다.

타임존 검증: 방문 기록만 데이터 명세서에서 **KST**로 명시됐다. 이에 출입 로그의 시각 기준을 확인하기 위해 두 테이블의 입실 시간대 분포를 비교했다.

구분	입실 피크 시각
방문 기록 (KST)	13시
출입 로그 (원본)	06시
출입 로그 (+9시간 보정 후)	15시

표 3. 타임존 보정 전후 입실 피크 시각

출입 로그의 원본 입실 시각은 **04~06시**에 집중되어, **13시**에 피크를 보이는 방문 기록(KST)과 시간대 분포가 크게 달랐다. 출입 로그에 **+9시간**을 적용하면 입실 피크가 **15시**로 이동해 방문 기록과 유사한 오후 시간대 분포를 보였다. 또한 보정 후 출입 로그의 체험 일차는 모두 **D0~D2** 범위에 포함되어, 신청일 이전으로 계산되는 기록이 없었다. 이를 바탕으로 출입 로그의 시각을 **UTC** 기준으로 판단하고 **+9시간**을 적용해 **KST**로 보정했다. 보정 후 남은 약 **2시간**의 피크 차이는 출입 로그가 재입실을 포함해 하루 중 모든 입실을 기록하기 때문으로 본다.

3.2 중복 처리

중복은 성격에 따라 세 유형으로 나누어 처리했다.

유형	대상	기준	건수	처리
완전 중복	신청·결제·방문·출입 로그	모든 값이 같은 행	470행	제거
복수 신청	신청	같은 사용자, 다른 신청일	7명	사용자 제외
부분 중복	방문	같은 사용자·날짜·지점, 값은 다름	76행	1행으로 집계

표 4. 중복 유형별 처리 기준

3.2.1 완전 중복

모든 컬럼 값이 같은 행은 같은 기록이 두 번 저장된 것으로 보고 제거했다. 출입 로그는 이벤트 고유번호(id)를 기준으로 판단했다.

테이블	중복 기준	처리 전	처리 후	제거
신청	전체 컬럼	9,659	9,631	28
결제	전체 컬럼	9,659	9,624	35
방문	전체 컬럼	11,477	11,429	48
출입 로그	이벤트 id	63,708	63,349	359

표 5. 테이블별 완전 중복 제거 결과

완전 중복 제거 후 동일 사용자·날짜·지점에 여러 방문 조각이 남은 76행은 체류시간 합계, 최초 입실 최솟값, 최종 퇴실 최댓값으로 집계했다. 집계 전에 시각 결측 플래그를 생성해 일부 조각의 결측이 집계 과정에서 가려지지 않도록 했다.

3.2.2 복수 신청

완전 중복을 제거한 뒤에도 신청 테이블에 사용자 중복 7건이 남았다. 확인 결과 모두 신청일이 서로 다른 2건의 신청으로, 명세서상 "3일 체험은 유저당 1회"라는 조건에 어긋난다. 어느 체험 기간의 행동이 결제로 이어졌는지 특정할 수 없어 7명을 제외 대상으로 분류했다.

3.2.3 부분 중복

부분 중복 처리는 시각 결측 복원(3.3) 이후 수행했다.

같은 사용자·날짜·지점이 여러 행인 경우가 76행 남았다. 값이 서로 다른 행들로, 같은 날짜 시간 구간이 이어지거나 떨어진 방문 조각이었다. 이를 체류시간 합계, 첫 입실 최솟값, 마지막 퇴실 최댓값으로 1행으로 집계했다(11,429 → 11,389행).

이 집계는 시각 결측 복원(3.3) 이후에 수행했다. 최솟값·최댓값 집계는 결측을 건너뛰기 때문에, 조각 중 하나에 결측이 있어도 집계 후에는 정상 값처럼 보일 수 있다. 이를 막기 위해 집계 전에 시각 결측 플래그를 먼저 만들어, 조각 중 하나라도 결측이면 결측으로 표시되도록 했다.

3.3 시각 결측 복원

방문 기록의 입·퇴실 시각에서 555행(332명)의 결측이 확인됐으며, 모두 2021년 5~6월에 집중되어 있었다. 체류시간은 기록되어 있어, 동일 사용자·날짜(KST)·지점의 출입 로그를 활용해 시각을 복원했다. 입실은 checkin=1 중 최솟값, 퇴실은 checkin=2 중 최댓값을 사용했다.

복원 방법은 시각이 정상인 8,413행에 먼저 적용해 실제 값과 비교했다.

허용 오차	입실 일치율	퇴실 일치율
1분 이내	93.9%	92.1%
10분 이내	94.7%	92.7%
1시간 이내	96.0%	94.4%

표 6. 출입 로그 기반 시각 복원 검증 결과

1분 이내 일치율이 입실 93.9%, 퇴실 92.1%였고, 허용 오차를 1시간까지 늘려도 일치율은 2%p 정도만 증가했다. 일치하는 경우는 대부분 1분 이내에서 일치하므로, 1분을 넘는 차이는 복원 오류일 가능성이 높다고 판단했다.

이에 따라 복원값은 입·퇴실 로그가 모두 존재하고, 퇴실이 입실보다 늦으며, 기록된 체류시간이 로그 구간 (퇴실 - 입실) 에 60초를 더한 값 이하인 경우에만 채택했다. 중간 외출 시 체류시간은 로그 기간보다 짧을 수 있으나 길 수는 없으므로, 체류시간이 로그 구간을 60초 넘게 초과하는 경우에만 복원 오류로 보았다. 허용 오차 60초는 위 검증의 1분 기준과 동일하게 설정했다.

처리 결과	행 수	처리
정합성 통과	395	복원
체류시간 불일치	78	복원 X
대응 로그 없음	65	복원 X
입 퇴실 중 한쪽 로그만 존재	17	복원 X
합계	555	-

표 7. 입·퇴실 시각 결측 복원 결과

555행 중 395행을 복원하고, 나머지 160행은 임의로 보정하지 않고 결측으로 남겼다. 복원된 행에는 별도 플래그를 부여했다. 그 결과 복원 후에도 체험 기간 내 시각 결측이 남은 129명은 사용자 단위로 제외했고, 복원을 통해 203명을 분석에 포함했다. 복원으로 포함된 사용자와 복원할 수 없어 제외된 사용자의 결제율은 각각 50.3%, 52.7%로 큰 차이가 없었다. 다만 두 집단 모두 전체 분석 대상의 결제율(37.8%)보다 높아, 결측 사용자 제외에 따른 편향이 없다고 단정하지 않고 한계로 남겼다.

3.4 테이블 정합성 확인 및 제외 기준

3.4.1 테이블 정합성 확인

테이블 간 사용자 집합을 비교해서 정합성을 확인했다.

확인 항목	결과	처리
신청 = 결제 사용자 집합	일치	-
방문·출입에만 있고 신청에 없는 사용자	0명	-
출입 로그는 있으나 방문 기록 없음	3명	제외 (데이터 불일치)
방문 기록은 있으나 출입 로그 없음	511명	제외하지 않고 출입 변수만 0

표 8. 테이블 간 사용자 정합성 검증 결과

방문 기록이 있으면서 출입 로그만 없는 511명은 실제 방문이 확인되는 고객이므로 제외하지 않았다. 대신 출입 로그 누락 여부를 별도 변수로 표시했다.

3.4.2 추가 제외 기준

데이터는 2023-12-31까지만 존재해, 2023-12-29 이후 신청자 27명은 D3가 데이터 범위 밖에 있어 체험 행동이 잘린다. 이들은 체험 기간 전체를 관찰할 수 없으므로 제외했다. 앞서 분류한 복수 신청 7명(3.2.2), 시각 복원 불가 129명(3.3), 테이블 불일치 3명(3.4.1)과 합쳐 총 166명을 제외했다(원본 9,624명 → 최종 9,458명). 제외 사용자는 사유와 함께 별도 파일로 저장했다.

3.4.3 사용자 테이블 생성

제외 기준을 반영해 신청·결제 테이블을 사용자 1명 = 1행으로 결합했다. 이 단계에서 최종 분석 대상(2.3)이 확정되며, 이후 방문·출입 집계는 모두 이 테이블을 기준으로 결합했다.

3.5 자정 이어짐 병합

방문 기록은 날짜 단위로 구분되어 있어, 자정을 넘긴 하나의 이용이 2개의 행으로 분리되는 문제가 확인됐다. 예를 들어 다음 두 기록은 실제로 하나의 연속된 방문이다.

기록	입실	퇴실	체류시간
행 1	2023-10-11 21:05:54	2023-10-11 23:59:59	10,444초
행 2	2023-10-12 00:00:00	2023-10-12 01:27:26	5,246초
병합 후	2023-10-11 21:05:54	2023-10-12 01:27:26	15,690초

표 9. 자정 연속 이용 병합 예시

아래 조건을 모두 만족하는 경우 두 행을 하나의 방문으로 병합했다.

- 같은 사용자·같은 지점
- 이전 행의 퇴실 시각이 23:59:59
- 현재 행의 입실 시각이 00:00:00
- 두 행의 날짜 차이가 1일

그 결과 605건의 행이 병합되어 방문 기록은 11,389행 → 10,784행으로 감소했으며, 00시 입실 기록은 857건 → 252건으로 감소했다.

병합은 체험 기간 필터보다 먼저 수행했다. 체험 마지막 날 밤에 시작해 다음 날까지 이어지는 방문을 먼저 병합하지 않으면, 체류시간의 일부가 잘릴 수 있기 때문이다. 병합 후에는 방문 시작일을 기준으로 체험 일차를 산정했다.

3.6 체험 기간 적용

자정 병합을 마친 방문 기록과 출입 로그에서 제외 사용자(3.4.2)의 기록을 제거한 뒤, 2.4에서 정의한 체험 기간(D0~D3)을 적용했다. 체험 일차는 방문은 병합된 방문의 시작일, 출입 로그는 KST 기준 날짜로 계산했다.

대상	제외 사용자 제거	체험 기간 필터 후
방문(세션)	10,784건 → 10,476건	10,476건
출입 로그	63,349건 → 61,930건	61,930건

표 10. 체험 기간 적용 전후 기록 수

원본 기록이 모두 D0~D3 범위 안에 있어 체험 기간 필터로 제외된 기록은 없었다. 최종 방문은 10,476건, 방문자는 6,377명이다.

3.7 체류시간 이상치 확인

체류시간 이상치는 삭제하지 않고 확인만 하였다. 24시간 운영 공유 오피스라 긴 체류도 실제로 가능하기 때문이다.

확인 항목	건 수	판단
체류시간 0초 이하	0	오류 없음
60초 미만	19	유지
24시간 초과	49	장시간 연속 이용 기록으로 보고 유지

표 11. 체류시간 이상치 검토 결과

체류시간은 중앙값 약 4.2시간(15,066초), 최대 약 69시간이었다. 최종 모델은 트리 기반으로 극단값의 영향을 적게 받아, 별도 변환 없이 사용했다.

3.8 사용자 피처 생성

체험 기간(D0~D3)의 방문·출입 기록을 사용자 단위로 집계한 뒤, 사용자 테이블(3.4.3)에 left join해 최종 사용자 9,458명의 1인 1행 데이터를 만들었다. 피처는 방문 지속성(10개), 이용시간(5개), 이용 시간대(7개), 지점(3개), 출입 빈도(6개), 방문 여부·주말 이용(2개), 신청 시점(3개)으로 구성된 총 36개다.

방문자 6,377명은 방문·출입 기록으로 모든 피처를 계산했다. 방문 기록은 있으나 출입 로그가 없는 고객은 출입 변수를 0으로 두고 별도 변수(access_log_missing)로 표시했다.

미방문자 3,081명은 횡수·시간·비율 변수를 0으로 채웠다. 첫 입실 시각, 주 이용 지점처럼 방문해야 정의되는 변수는 0을 넣으면 "0시 입실"로 잘못 읽힐 수 있어 결측으로 두었다.

시각 복원 여부는 복원 사용자가 2021년 5~6월 고객에 한정되어 가입 시기를 대신 나타낼 수 있으므로, 모델 피처에서 제외하고 확인용으로만 보관했다. 이후 5.3에서 파생변수 10개를 추가해 모델 후보 변수는 46개가 된다.

4. 탐색적 데이터 분석

4.1 무료체험 퍼널

무료체험 신청 고객 9,458명 중 실제 방문 고객은 6,377명으로, 신청 후 방문율은 67.4%였다. 신청 고객의 32.6%인 3,081명은 체험을 신청했지만 방문 기록이 확인되지 않았다.

방문 고객 중 서로 다른 날짜에 2일 이상 방문한 재방문 고객은 2,955명으로, 방문자 기준 재방문율은 46.3%였다. 전체 신청자 기준으로는 31.2%가 재방문한 것으로 나타났다. 신청 이후 첫 방문 단계에서 3,081명, 첫 방문 이후 재방문 단계에서 3,422명이 이탈해 두 구간 모두 상당한 이탈이 확인되었다.

이는 무료체험 신청을 실제 방문으로 연결하는 과정뿐 아니라, 첫 방문 경험을 이후 방문으로 연결하는 과정도 개선할 필요가 있음을 보여준다. 특히 방문 고객의 절반 이상인 한 날짜에만 이용한 만큼, 첫 방문 이후 남은 체험 기간을 안내하거나 다음 방문을 유도하는 메시지와 서비스 경험을 검토할 수 있다.

다만 결제 시점 정보가 제공되지 않아 신청·방문·재방문·결제를 시간순으로 연결할 수 없다. 따라서 본 분석에서는 신청 → 방문 → 재방문을 이용행동 퍼널로 정의하고, 결제 여부는 각 이용 단계와의 관련성을 별도로 분석하였다.




그림 2. 무료체험 신청·방문·재방문 퍼널

4.2 재방문과 결제

- 1일 방문 고객 결제율: 33.5%
- 미방문 고객 결제율: 약 35.2%
- 재방문 고객 결제율: 45.2%
- 비재방문 고객 결제율: 34.3%
- 재방문 여부에 따른 결제율 차이: 10.8%p

1일 방문 고객의 결제율이 미방문 고객과 유사한 반면, 여러 날 방문한 고객은 더 높은 결제율을 보였다. 재방문은 결제 고객에게 자주 나타나는 행동이지만, 재방문 고객의 절반 이상이 결제하지 않았으므로 재방문 하나만으로 결제를 판별할 수는 없다.




그림 3. 방문 단계별 고객 수와 결제율

4.3 체류시간과 결제

총 체류시간별 결제율은 0~2시간 구간 약 38%, 2~4시간 구간 약 41%로 나타났으며, 이후 체류시간이 증가할수록 완만하게 낮아져 16시간 이상 구간에서는 약 35%였다.

방문일 평균 체류시간과 최대 하루 체류시간에서도 0~4시간 구간의 결제율이 가장 높고, 8시간 이상부터 낮아지는 경향이 나타났다. 다만 장시간 이용 구간은 표본이 적고 고객의 이용 목적이 다를 수 있어, 장시간 이용이 결제를 낮춘다고 해석하기는 어렵다.




그림 4. 체류시간 지표별 구간 결제율

4.4 첫 입실 시각 및 시간당 방문 세션 수와 결제

첫 입실 시각별 결제율은 16시 이후 구간에서 전체 결제율보다 높게 나타났다. 16~18시는 약 43%, 18~20시와 20~22시는 약 50%, 22~24시는 약 49%의 결제율을 보였다. 다만 20시 이후 구간은 상대적으로 표본 수가 적고, 직업이나 이용 지점 등 다른 요인의 영향이 반영되었을 가능성이 있다.

시간당 방문 세션 수에 따른 결제율은 중간 구간에서 높게 나타났다. 0.25회 이하인 약 35%였으나, 0.25 ~ 2회 구간은 약 44 ~ 45%으로 높아졌고, 2회 이상에서는 약 34%로 낮아졌다. 이는 입실 빈도와 결제가 단순한 선형관계가 아님을 확인할 수 있다.

모델에서는 첫 입실 시각이 아니라 평균 입실 시각을 사용했지만, 분석 결과 늦은 시간대에 입실하는 고객일수록 결제확률이 높아지는 경향이 확인됐다.




그림 5. 첫 입실 시각 및 시간당 방문 세션 수별 결제율

4.5 EDA 종합

재방문, 방문 시점, 체류시간, 입실 빈도에 따른 고객군별 결제율 차이가 확인됐다. 특히 저녁 시간대 이용과 일정 수준의 입실 빈도에서 상대적으로 높은 결제율이 확인됐다. 반면 체류시간은 길수록 결제율이 높아지는 관계를 보이지 않았다.

각 변수는 고객의 이용 목적과 지점 특성 등의 영향을 함께 받을 수 있으므로 인과관계로 해석하기 어렵다. 이에 여러 행동변수를 종합했을 때 결제 고객을 어느 정도 구분할 수 있는지 지도학습 분류 모델로 검증하고자 한다.

5. 결제 전환 예측 모델링

5.1 문제 정의

다음 표는 결제 전환 예측 모델의 학습 방식, 정답 변수와 분석 대상, 입력 변수 및 활용 목적을 정리한 것이다.

항목	내용
학습 방식	지도학습 이진 분류
정답 변수	is_payment (결제 = 1, 미결제 = 0)
주 모델 대상	관찰 기간 안에 방문 행동이 있는 고객 (미방문자는 행동 데이터가 없어 모델 대상에서 제외하고, 퍼널·EDA에서 다룬다)
입력 변수	방문 지속성, 체류시간, 출입 빈도, 이용 시간대, 지점, 신청 시점
활용 목적	무료체험 데이터를 통해 결제전환 고객을 예측할 수 있는지 검토하고, 결제 전환 관련성이 높은 변수를 파악하는 것

표 12. 결제 전환 예측 모델 구성

본 분석은 무료체험 신청자 중 실제 방문 행동이 확인된 고객을 대상으로, 방문 지속성·체류시간·출입 빈도·이용 시간대·지점·신청 시점 등의 변수를 활용해 결제 여부를 예측하는 지도학습 기반 이진 분류 모델이다.

미방문자는 행동 데이터가 없어 모델링 대상에서는 제외하고 퍼널과 EDA에서 별도로 분석했으며, 이를 통해 고객의 결제 전환 가능성을 예측하고 전환과 관련성이 높은 주요 행동요인을 파악하고자 한다.

5.2 모델링 파이프라인



그림 6. 모델 학습 및 검증 파이프라인




그림 7. 변수 선택·튜닝 및 최종 평가 절차

학습 데이터 안에서만 피처 생성, 변수 선택, 튜닝을 진행하고 **5-fold** 교차검증을 통해 모델의 안정성을 확인하였다. 이후 **OOF** 예측값으로 최종 임계값을 결정했으며, 테스트 데이터는 모든 모델링 과정이 끝난 뒤 한 번만 사용해 최종 성능을 평가하였다. 이러한 방식은 테스트 정보가 학습에 반영되는 데이터 누수를 방지하고, 모델의 실제 일반화 성능을 객관적으로 확인하기 위한 것이다.

5.3 파생변수

기존 집계 변수에 고객의 이용 방식을 나타내는 **10개** 변수를 추가했다. 파생변수는 체류시간과 입실 시간대를 구분한 구간 변수, 체험 기간 활용 정도를 나타내는 비율 변수, 이용 집중도를 측정하는 강도 변수, 체류시간 변화를 나타내는 추세 변수, 첫 방문 지연 여부를 나타내는 시점 변수로 구성하였다.

유형	파생변수	의미
구간	stay_level, entry_time_group	체류시간 등급, 입실 시간대
비율	visit_ratio, first_day_share, evening_ratio, weekend_ratio	방문 활용률, 첫날 집중도, 저녁·주말 이용 비중
강도	avg_stay_per_session, entries_per_hour	세션당 체류 강도, 시간당 입실 빈도
추세	stay_trend	일차별 체류시간 증가·감소
시점	late_start	첫 방문 지연 여부

표 13. 파생변수 정의

모든 파생변수는 체험 관찰 기간인 신청일로부터 0~3일차까지의 정보만 사용해 생성했으며, 정답 변수인 **is_payment**는 생성 과정에 사용하지 않았다. 이를 통해 데이터 누수를 방지하면서 고객의 방문 패턴과 공간 이용 특성을 모델에 반영하였다.

5.4 변수 선택

단계	변수 수	내용
사용자 피처 (3.8)	36	방문 및 출입 기록 집계
파생변수 추가 (5.3)	46	+10개
상수 및 준상수 제거	44	visited, short_visit_count 제거
상관 제거	24	스피어만 $ r \geq 0.8$ 인 쌍에서 결제 관련성이 낮은 쪽 20개 제거
모델별 선택	15	CatBoost : 후보 44개 중 중요도 상위 k개를 교차검증으로 비교해 선택

표 14. 변수 선택 단계별 변수 수

변수 선택은 학습 데이터(방문 고객)만 사용해 다음 순서로 진행했다.

1. 상수·준상수 제거: 한 값이 99.5% 이상을 차지하는 변수는 결제 고객을 구분하는 데 도움이 되지 않으므로 제거했다. 방문 고객만 대상으로 하여 항상 1인 **visited**와 값이 거의 0인 **short_visit_count**가 제거되어 44개가 남았다.

2. 의미 중복 분류: 방문 횟수, 체류시간, 출입 빈도, 이용 시간대 등 정의상 유사한 정보를 담는 변수를 그룹으로 묶었다. 이 분류는 상관 제거 결과를 해석하고 제거 기준을 설명하는 근거로 활용했다.
3. 결제 관련성 확인: 수치형 변수는 단변량 **AUC**로 관련성을 확인했다. 단변량 **AUC**는 변수 하나로 결제자와 미결제자를 얼마나 잘 구분하는지를 나타내며, **0.5**에서 멀수록 관련성이 크다. 방향과 관계없이 비교하기 위해 **|AUC - 0.5|**를 사용했다. 범주형 변수는 크기 비교가 의미 없으므로 카이제곱 검정으로 확인했다.
4. 상관 제거: 스피어만 상관계수가 **0.8** 이상인 변수 쌍은 같은 정보를 담은 것으로 보고, 3단계에서 결제 관련성이 더 높은 변수를 남겼다. 수치형 **20**개가 제거되어 범주형을 포함한 공통 피처 **24**개가 남았으며, 이는 **5**개 모델을 같은 조건에서 비교하는 데 사용했다.
5. 모델별 변수 선택: 트리 모델은 후보 **44**개에서, 로지스틱 회귀는 공통 피처 **24**개에서 출발했다. 모델별 중요도 상위 **k**개 조합을 교차검증으로 비교하고, 최고 **AUC**와 **0.002** 이내인 조합 중 변수가 가장 적은 조합을 선택했다.

그 결과 **CatBoost**는 **44**개 사용 시 **CV ROC-AUC 0.640**, **15**개 사용 시 **0.639**로 성능 차이가 거의 없어, **15**개를 최종 변수로 선택해 모델의 복잡도를 낮췄다. 다만 최종 **15**개 중 **6**개는 상관 제거 단계에서 제외됐던 변수로, 서로 관련성이 높은 체류시간 변수가 함께 포함되어 있다.

5.5 임계값

분석 임계값은 학습 데이터의 **OOF** 예측을 이용해 결제 예상 고객 비율을 **50%** 이하로 제한하면서 **F1**이 최대가 되는 값으로 정했다. 테스트 고객 중 **659**명을 결제 예상으로 분류했고, 이 가운데 **330**명이 실제 결제 고객이었다. 실제 결제 고객 **496**명 중 **330**명을 포착했고 **166**명을 놓쳤다.

		예측	
		결제	미결제
실제	결제	330 TP	166 FN
	미결제	329 FP	432 TN

결제 고객 10명 중 약 6.7명 포착

그림 8. 분석 임계값 적용 결과 혼동행렬

	실제 결제	실제 미결제
결제 예측	330	329
미결제 예측	166	432

표 15. 분석 임계값 적용 결과 혼동행렬

테스트 결제율 39.5%와 비교하면 결제 예상 집단의 실제 결제율은 50.1%로 약 1.27배 높았다. 모델은 완전한 자동 판정 도구라기보다 제한된 상담·마케팅 대상의 우선순위를 정하는 보조 도구로 해석한다.

5.6 최종 모델 성능

최종 CatBoost 모델은 방문 고객 테스트 데이터 1,257명에서 다음 결과를 보였다.

지표	결과
교차검증 ROC-AUC	0.641
테스트 ROC-AUC	0.648
방문일수 기준선 테스트 ROC-AUC	0.591
운영 임계값	0.366
Precision	0.501
Recall	0.665
F1	0.571
Accuracy	0.606

표 16. 최종 CatBoost 모델 성능

교차검증 ROC-AUC는 0.641, 테스트 ROC-AUC는 0.648로 유사하게 나타나 과적합 가능성이 낮고 새로운 데이터에서도 비교적 안정적인 성능을 보였다. 또한 방문일 수만 사용한 기준선 모델보다 테스트 ROC-AUC가 0.057 높아 다양한 이용행동 변수의 추가 효과를 확인할 수 있었다.

운영 임계값 0.366을 적용한 결과, 결제 대상으로 예측한 고객 중 50.1%가 실제 결제했고(Precision), 실제 결제 고객 중 66.5%를 포착했다(Recall). F1은 0.571로 나타났으며, 본 모델은 결제 여부를 완전히 판정하기보다는 결제 가능성이 높은 고객을 선별하여 마케팅 우선순위를 정하는 용도에 적합하다.


6. 모델 해석

SHAP은 각 변수가 모델 예측에 사용된 정도와 방향을 보여주고, **Permutation Importance**는 테스트 데이터에서 변수를 섞었을 때 **AUC**가 얼마나 감소하는지를 보여준다. 두 방법에서 공통으로 중요하고 **Permutation** 기여가 확인된 변수를 핵심 신호로 해석했다.

변수	SHAP 방향	테스트 AUC 감소	해석
마지막 방문 시점	늦을수록 결제 확률↑	0.0372	체험 후반까지 방문한 고객의 전환 가능성이 높게 예측됨
방문 기간 폭	넓을수록 결제 확률↑	0.0203	여러 날짜에 걸쳐 이용한 고객의 전환 가능성이 높게 예측됨
평균 입실시간	늦을수록 결제 확률↑	0.0157	저녁 이용 특성이 예측에 기여함
주 이용 지점	범주별 차이	0.0080	지점에 따라 고객 구성 또는 운영 조건이 다를 가능성
첫날 이용 집중도	높을수록 결제 확률↓	0.0069	첫날에 이용이 몰리고 이후 이용이 줄어드는 고객의 전환 가능성이 낮게 예측됨
신청 월	범주별 차이	0.0063	계절, 프로모션, 운영 변화 등 시기 효과 가능성

표 17. 주요 변수의 예측 기여도와 방향

평균 체류시간과 총 체류시간은 SHAP에서 음의 방향을 보였지만 **Permutation** 기여는 불확실했다. 따라서 ‘체류시간이 길면 결제가 감소한다’고 단정하지 않고, EDA에서 관찰된 추가 검증 가설로만 사용한다.



7. 비즈니스 활용 및 서비스 개선 제안

7.1 활용 원칙

검증된 변수 중심으로 활용한다.

SHAP과 순열 중요도에서 기여도가 확인된 마지막 방문일, 방문 기간, 평균 입실 시각을 중심으로 개선안을 도출한다.

예측 관계를 인과관계로 단정하지 않는다.

모델 결과는 결제와 관련된 행동 특성을 보여준다. 제안한 서비스가 실제 결제율을 높이는지는 대조 실험을 통해 확인한다.

결제율을 최종 성과로 평가한다.

재방문과 이용 지속성은 중간지표로 활용하고, 개선안의 최종 효과는 결제 전환율로 판단한다.

7.2 액션 제안

A. 체험 기간 내 지속적인 방문 유도

모델에서는 마지막 방문일이 낮고 첫 방문부터 마지막 방문까지의 기간이 긴 고객일수록 결제확률이 높게 예측됐다. 이는 첫날에 이용이 집중된 고객 행동보다 체험 기간 후반까지 이용을 이어간 고객 행동이 결제 고객을 구분하는 데 더 유용하다는 의미다.

이에 첫 방문 고객을 대상으로 다음 방문을 유도하는 서비스 실험을 제안한다.

- 첫 방문 다음 날 남은 체험 기간과 이용 가능 서비스 안내
- 아직 방문하지 않은 지정·공간·편의시설 추천
- 체험 종료 전 미사용 혜택과 남은 이용 기간 알림
- 두 번째 방문 시 상담 또는 상품 안내 제공

검증 방법은 7.3에서 설명한다.

B. 저녁 이용 고객을 위한 서비스 최적화

모델에서는 평균 입실 시각이 늦을수록 결제확률이 높아지는 경향이 확인됐다. EDA에서도 저녁 시간대에 처음 입실한 고객의 결제율이 상대적으로 높게 나타나, 저녁 이용 고객이 주요 전환 후보군일 가능성을 확인했다.

이에 저녁 이용 고객에게 적합한 운영 방식을 검토한다.

- 저녁 시간대 상품 및 이용 방법 안내 강화
- 야간 상담 채널 또는 비대면 상담 제공
- 야간 이용이 가능한 공간과 편의시설 안내
- 퇴근 후 이용 고객을 위한 시간제·야간 상품 검토

평균 입실 시각은 고객의 직업이나 이용 목적을 대신 나타낸 변수일 수 있으므로, 저녁 이용 자체가 결제를 증가시킨다고 단정하지 않는다. 야간 안내와 상담을 제공하는 실험을 통해 실제 결제율 개선 여부를 확인한다.

C. 결제 가능 고객의 우선순위 설정

체험이 종료된 시점에는 마지막 방문일, 방문 기간, 평균 입실 시각을 포함한 모델 예측확률을 이용해 미 결제 고객의 후속 상담 우선순위를 정할 수 있다.

- 고전환 가능군: 빠른 상품 상담과 맞춤형 요금제 안내
- 중전환 가능군: 이용패턴에 맞는 상품과 추가 혜택 안내
- 저전환 가능군: 미결제 사유 조사와 서비스 개선 설문

이 활용안은 결제를 확정적으로 예측하기 위한 것이 아니라, 무료체험 종료 시점에서, 제한된 상담 인력과 마케팅 비용을 미결제 고객 중 상대적으로 전환 가능성이 높은 고객에게 우선 배분하기 위한 것이다.

7.3 검증 방법

모델과 EDA는 관련성을 보여주지만 서비스 개입의 효과를 증명하지 않으므로, 제안한 액션은 무작위 A/B 테스트로 검증한다. 우선 실험은 EDA와 모델에서 근거가 가장 뚜렷하고 메세지 발송만으로 실행할 수 있는 A(체험 기간 내 지속적인 방문 유도)를 정했다.

항목	설계
가설	첫 방문 이후 남은 체험 일정과 이용 가능한 서비스를 안내하면 체험 기간 내 이용이 지속되고 최종 결제율이 높아진다.
대상	D0~D2에 첫 방문을 완료한 미 결제 고객
배정	사용자 단위로 실험군과 대조군에 무작위 배정
실험군 / 대조군	첫 방문 이후 단계별 재방문 안내 제공 / 기존 운영 유지
중간지표	재방문율, 마지막 방문일, 첫 방문부터 마지막 방문까지의 기간
비용 지표	메시지 발송비와 상담 운영비
최종 KPI	결제 전환율
성공 기준	실험군의 결제율이 대조군보다 높고, 추가 결제로 발생한 기대수익이 개입 비용보다 큰 경우

표 18. 첫 방문 후 재방문 안내 A/B 테스트 설계

실험에서는 메시지 발송 시각과 결제 시각을 함께 수집해, 안내 이후 발생한 결제만 성과로 측정한다.

B와 **C**도 같은 방식으로 검증한다. **B**는 저녁 입실 고객 중 실험군에만 야간 상품/상담을 안내하고, **C**는 예측확률 상위 미결제 고객 중 실험군에만 우선 상담을 제공해 결제율을 비교한다.

8. 한계와 추가 필요 데이터

8.1 분석 한계

1. 결제 시각 부재: 행동이 결제보다 먼저 발생했는지 확인할 수 없다.
2. 인과관계 한계: **SHAP**과 결제율 차이는 관련성을 보여줄 뿐 행동 변화의 효과를 증명하지 않는다.
3. 미방문 고객 예측 한계: 행동이 없어 현재 행동 모델의 대상에서 제외되며, 전체 신청자 대상 운영을 위해 별도 피처가 필요하다.
4. **D3** 포함에 따른 활용 시점: 체험 전체 행동을 사용하므로 체험 진행 중 초기 개입에는 사용할 수 없고, 다음 상담·후속 전환 관리에 활용 범위가 제한된다.
5. 시기 효과: 신청 월과 일부 복원 변수가 수집 시기·프로모션 변화를 반영할 수 있다.
6. 고객 배경 부재: 이용 목적, 직업, 기업 규모, 가격 민감도 등의 정보가 없다.
7. 운영 정보 부족: 지점 면적 외에 좌석 구성, 혼잡도, 가격, 상담 품질이 없다.
8. 무작위 분할: 같은 기간 분포에서의 일반화는 확인했지만 미래 시점에서의 성능은 별도 시간순 검증이 필요하다.

8.2 추가 수집 데이터 제안

- 결제 일시와 상품 · 활용 목적: 행동과 결제의 선후관계, 상품별 전환 분석
- 체험 유입 채널 · 활용 목적: 마케팅 채널별 고객 품질과 비용 효율 분석
- 가격·할인 노출 · 활용 목적: 가격 민감도와 프로모션 효과 분석
- 이용 목적·직업·기업 규모 · 활용 목적: 행동이 비슷하지만 결제가 다른 고객 설명
- 만족도·불편 사유 · 활용 목적: 공간 경험과 결제 장벽 확인
- 상담·메시지·쿠폰 이력 · 활용 목적: 서비스 개입의 증분 효과 측정
- 지점 좌석·혼잡도·시설 · 활용 목적: 지점 차이의 운영 원인 분석

9. 결론

무료체험 고객의 행동에서는 재방문, 방문 시점, 이용 시간대와 결제 여부 사이에 차이가 관찰됐다. 특히 여러 날짜에 걸쳐 체험 후반까지 방문한 고객은 결제 가능성이 높게 예측됐고, 첫날에 이용이 집중된 고객은 상대적으로 낮게 예측됐다. 반면 장시간 체류가 높은 결제로 직접 이어진다는 가정은 지지되지 않았다.

방문일수 하나만 사용한 기준선보다 다양한 행동을 결합한 **CatBoost** 모델의 테스트 **ROC-AUC**가 **0.591**에서 **0.648**로 높아져 행동 조합의 추가 정보는 확인됐다. 다만 **Precision 50.1%** 수준이므로 모델을 결제 여부의 자동 판정에 사용하는 것은 적절하지 않다. 상담과 실험 대상의 우선순위를 정하는 보조 도구로 제한해 활용해야 한다.

서비스 개선의 첫 우선순위는 첫 방문 후 재방문을 유도하는 안내 실험이다. 이후 저녁 이용 고객의 상품 적합성, 지점별 운영 차이, 장시간 미결제 고객의 이용 목적을 확인한다. 향후에는 결제 시각, 가격, 고객 목적, 만족도 및 서비스 개입 이력을 추가해 예측력과 실행 가능성을 높이고, 각 개선안의 실제 결제 효과는 **A/B** 테스트로 검증해야 한다.

부록 A. 보고서용 핵심 수치

구분	수치
최종 분석 고객	9,458명
방문 고객	6,377명 (67%)
재방문 고객	2,955명 (31%)
재방문 결제율	45.2%
비재방문 결제율	34.4%
시각 결측	555행
시각 복원	395행
복원 검증 입실 일치율	93.9%
복원 검증 퇴실 일치율	92.1%
최종 모델	CatBoost
테스트 고객	1,257명
테스트 ROC-AUC	0.648
분석 임계값	0.366
Precision	0.501
Recall	0.665
F1	0.571

표 19. 분석 핵심 수치

부록 B. 모델 비교 및 개선

모델 비교와 개선은 학습 데이터의 총화 5-fold 교차검증 ROC-AUC를 기준으로 진행하였다. 로지스틱 회귀, 랜덤 포레스트, XGBoost, LightGBM, CatBoost를 비교했으며, 무작위 예측과

방문일수만 사용한 로지스틱 회귀를 기준선으로 설정하였다. 테스트 데이터는 최종 모델을
확정한 이후에만 사용하였다.

단 계	모델	CV ROC-AUC	해석
B0	Dummy	0.500	무작위 수준 기준선
B1	방문일수 로지스틱 회귀	0.564	행동 1개 기준선
R1	CatBoost, 공통 피처 24개	0.642	다양한 행동 추가 효과
R2	CatBoost, 선택 피처 15개	0.639	성능을 유지하며 단순화
R2	튜닝 CatBoost	0.641	선택 후 성능 회복
R3	CatBoost+LightGBM 투표	0.644	단일 모델 대비 +0.0029로 미채택

표 20. 모델 비교 및 개선 결과

공통 피처 24개를 사용한 기본 비교(R1)에서는 CatBoost가 0.642로 가장 높은 성능을
보였다. 이후 모델별 변수 선택(R2-a)에서 CatBoost는 후보 44개 중 중요도 상위 15개를
선택했으며, 교차검증 ROC-AUC는 0.640(44개)에서 0.639(15개)로 차이가 0.002 이내였다.
파라미터 조정 후 ROC-AUC는 0.641이었다.

클래스 가중치는 Recall을 높였지만, 모든 모델에서 ROC-AUC 개선폭이 채택 기준인
0.005에 미치지 못해 적용하지 않았다. CatBoost와 LightGBM을 결합한 앙상블(R3)은
0.644로 가장 높은 성능을 보였지만, 단일 CatBoost 대비 개선폭이 0.0029로 채택 기준에
미치지 못했다. 이에 1위와의 차이가 0.005 미만인 단일 모델(CatBoost, 랜덤 포레스트,
LightGBM) 중 교차검증 표준편차가 가장 작은 CatBoost(0.0127)를 최종 모델로 선정하였다.




그림 10. 모델 개선 단계별 교차검증 *ROC-AUC* 변화

방문일수만 사용한 기준 모델보다 여러 이용행동을 반영했을 때 교차검증 *ROC-AUC*가 0.564에서 0.642로 상승했다. 반면 변수 선택 이후의 튜닝과 앙상블에서는 개선폭이 제한적이었다. 최종적으로 근소한 성능 차이보다 모델의 안정성과 해석 편의성을 고려해 CatBoost 단일 모델을 선택하였다.